

B站弹幕情感分析项目文件讲解

本文档用于说明本项目中各个文件和文件夹的作用，方便答辩、提交作业、后续修改和整理目录。

1. 项目整体作用

本项目主题是“B站学习区与生活区弹幕情感对比分析”。项目会完成以下流程：

输入两个 BV 号
-> 爬取学习区和生活区弹幕
-> 清洗弹幕文本
-> 使用 jieba 分词、TF-IDF、字级 n-gram、HowNet/知网情感词典构造特征
-> 训练朴素贝叶斯、逻辑回归、SVM、随机森林
-> 选择表现最好的模型
-> 对真实弹幕进行正面/中性/负面分类
-> 人工复核低置信样本并继续学习
-> 输出 CSV 结果、图表和实验摘要

当前项目支持“四轮主动学习”：

- ？第 1 轮：模型先分析一遍，并抽取最多 100 条不确定样本让人工标注。
- ？第 2 轮：读取第 1 轮人工标注，再训练和分析。
- ？第 3 轮：继续读取前两轮人工标注，再训练和分析。
- ？第 4 轮：最终轮，不再提问，输出最终结果。

最终汇报和提交时，主要看 `final_round_4`。

2. 根目录文件说明

README.md

项目的主要使用说明文件。里面包含：

- ？如何安装依赖。
- ？如何运行一键实验脚本。
- ？输入 BV 号的方法。
- ？输出结果在哪里看。
- ？人工复核标签怎么填。
- ？词典和主动学习的说明。

这是别人拿到项目后最应该先看的文件。

README.pdf

由 README.md 转换得到的 PDF 版本。作用和 README.md 一样，只是更方便打印、提交或直接打开阅读。

项目文件讲解.md

当前这份说明文档的 Markdown 源文件。它说明项目里每个主要文件和文件夹的用途。

项目文件讲解.pdf

当前这份说明文档的 PDF 版本。它是给阅读、提交和答辩使用的最终说明文件。

requirements.txt

项目依赖列表。运行项目前需要安装这里列出的第三方库。

常用命令：

```
python -m pip install -r requirements.txt
```

当前主要依赖包括：

- ? **pandas**：读写 CSV、统计数据。
- ? **numpy**：数值计算。
- ? **scikit-learn**：机器学习模型、TF-IDF、评价指标。
- ? **matplotlib**：画图。
- ? **requests**：请求 B站接口。
- ? **jieba**：中文分词。
- ? **wordcloud**：词云相关依赖。
- ? **python-docx**、**python-pptx**：用于文档和 PPT 相关操作。

大数据作业.docx

老师或课程给出的原始作业要求文档。它说明这个项目需要完成哪些任务，例如爬虫、情感分析、模型对比、可视化、报告和展示等。

基于大数据爬虫与机器学习的B站弹幕情感对比分析_项目报告.docx

项目报告文档。用于正式提交或作为课程作业报告。一般包含：

- ? 项目背景。
- ? 数据采集方法。
- ? 数据处理过程。

- ? 模型设计。
- ? 实验结果。
- ? 可视化分析。
- ? 总结。

B站弹幕情感对比分析_6分钟展示PPT.pptx

课堂展示用 PPT。适合 6 分钟左右的汇报，通常按照“研究背景 -> 方法流程 -> 模型结果 -> 可视化分析 -> 总结”的顺序讲。

09f10ecd97ddbdf9634c534d6b26588.jpg

项目中的图片素材文件。通常用于报告、PPT 或页面展示背景。它不是程序运行必需文件，删除后不影响爬虫和模型，但可能影响文档/PPT 的图片完整性。

3. src/ 源代码目录

src/ 是正式运行代码目录。项目真正执行时主要使用这里的 .py 文件。

src/run_experiment.py

项目的一键运行入口，也是最重要的运行脚本。

运行命令：

```
python src\run_experiment.py
```

它负责串起完整流程：

1. 询问实验名称。
2. 询问学习区 BV 号或视频链接。
3. 询问生活区 BV 号或视频链接。
4. 调用爬虫抓取弹幕。
5. 调用 `train_analyze.py` 训练模型和分析弹幕。
6. 前三轮每轮询问最多 100 条人工复核样本。
7. 第四轮输出最终结果。
8. 自动把结果归档到 `results/实验名/` 和 `figures/实验名/`。

这个文件本身不负责具体建模，它更像“总调度器”。

src/run_experiment.ipynb

由 `src/run_experiment.py` 转换得到的 Notebook 版本。适合在 Jupyter 或 VS Code Notebook 里分块阅读代码。

注意：正式运行建议仍然用 `.py` 文件，因为这个脚本包含终端输入交互，Notebook 里运行不一定更方便。

`src/crawler_bilibili.py`

B站弹幕爬虫脚本。它负责：

1. 根据 BV 号请求 B站视频信息接口。
2. 获取视频的 `cid`。
3. 根据 `cid` 请求 XML 弹幕接口。
4. 解析 XML 中的弹幕文本。
5. 保存为 CSV。

输出字段包括：

? `partition`: 分区，例如学习区、生活区。

? `bvid`: 视频 BV 号。

? `title`: 视频标题。

? `view_count`: 播放量。

? `like_count`: 点赞量。

? `coin_count`: 投币量。

? `favorite_count`: 收藏量。

? `reply_count`: 评论量。

? `danmaku_count`: 弹幕总量。

? `text`: 弹幕文本。

如果 B站接口风控导致请求失败，可以在 `HEADERS` 中补充浏览器 Cookie。

`src/crawler_bilibili.ipynb`

`crawler_bilibili.py` 的 Notebook 版本，方便逐块查看爬虫逻辑。

`src/train_analyze.py`

项目最核心的分析脚本。它负责：

1. 读取训练数据。
2. 读取真实爬取弹幕。

3. 清洗文本。
4. 使用 `jieba` 中文分词。
5. 读取 HowNet/知网情感词典。
6. 构造词级 TF-IDF 特征。
7. 构造字级 2-4gram TF-IDF 特征。
8. 构造情感词典特征，例如正面词数量、负面词数量、情感分数等。
9. 训练四种模型：
 - ? 朴素贝叶斯。
 - ? 逻辑回归。
 - ? SVM。
 - ? 随机森林。
10. 比较模型准确率和 F1。
11. 选择最优模型。
12. 对全部真实弹幕预测情感。
13. 根据模型概率、词典分数和人工规则修正最终标签。
14. 导出正面、中性、负面弹幕。
15. 生成分区统计、模型报告、混淆矩阵和图表。
16. 抽取低置信/冲突样本供人工复核。

它是决定分类结果准确不准确的关键文件。

`src/train_analyze.ipynb`

`train_analyze.py` 的 Notebook 版本。适合阅读建模流程，尤其是查看每个函数的作用。

`src/make_sample_data.py`

演示样例数据生成脚本。如果 `data/danmu_sample_5000.csv` 不存在，程序可以自动调用它生成课堂演示用训练样本。

它生成的是模拟弹幕数据，不是真实 B站弹幕。真实实验主要依赖 `crawler_bilibili.py` 爬取的数据。

`src/make_sample_data.ipynb`

`make_sample_data.py` 的 Notebook 版本。

4. `data/` 数据目录

`data/` 用来保存训练数据、真实爬取弹幕、情感词典和人工反馈。

`data/danmu_sample_5000.csv`

训练样例数据。它用于训练初始模型，里面包含：

? `partition`: 分区。

? `bvid`: 视频或样例编号。

? `text`: 弹幕文本。

? `label`: 人工标注标签。

标签规则：

? `1`: 正面。

? `0`: 中性。

? `-1`: 负面。

这个文件对模型训练很重要。如果没有它，程序会自动生成演示数据，但真实效果会受影响。

`data/experiments/`

每次运行实验时，爬虫保存原始弹幕的地方。

目录结构示例：

```
data/experiments/  
  experiment_20260528_145329/  
    raw_bilibili_danmu.csv
```

其中：

? `experiment_20260528_145329`: 某一次实验。

? `raw_bilibili_danmu.csv`: 这次实验爬到的原始弹幕。

`data/experiments/*/raw_bilibili_danmu.csv`

真实爬取的弹幕数据。它是每次实验的输入数据，后续模型会对它进行预测和分析。

这个文件一般不要手动改，除非你明确知道自己要清洗或替换爬虫数据。

`data/sentiment_lexicon/hownet_positive.txt`

正面情感词典。项目会把它和代码里的兜底词表合并成 `POS_WORDS`。

它用于：

? 计算正面词数量。

- ? 计算词典情感分数。
- ? 作为机器学习模型的辅助特征。
- ? 辅助最终情感标签修正。

`data/sentiment_lexicon/hownet_negative.txt`

负面情感词典。作用和正面词典类似，只是用于负面词。

注意：代码里会临时剔除一些容易误伤的单字词，例如 **好、强、牛、水**，避免短弹幕被错误分类。

`data/feedback/README.md`

人工反馈目录说明文件。它解释人工标注数据应该怎么放、怎么被程序读取。

`data/feedback/README.pdf`

`data/feedback/README.md` 的 PDF 版本。

5. `results/` 结果目录

`results/` 保存每次实验的 CSV、报告和文本摘要。它是查看模型分析结果的主要位置。

目录结构示例：

```
results/  
  experiment_20260528_145329/  
    round_1/  
    round_2/  
    round_3/  
    final_round_4/
```

含义：

- ? `experiment_20260528_145329`：一次完整实验。
- ? `round_1`、`round_2`、`round_3`：前三轮主动学习结果。
- ? `final_round_4`：最终结果，汇报时主要看这里。

每个轮次目录中常见文件如下。

`analysis_summary.md`

自动生成的实验摘要。包含：

- ? 最优模型。
- ? 模型准确率和 F1。

- ? 训练样本数。
- ? 人工反馈样本数。
- ? 分区情感比例。
- ? 简要建议。

`analysis_summary.pdf`

`analysis_summary.md` 的 PDF 版本，方便直接提交或阅读。

`classification_report.txt`

最优模型的文本版分类报告。里面记录模型名称、训练数据、预测数据、训练样本数、词典数量和模型指标。

`classification_report_full.csv`

更完整的分类指标表，通常包含每个类别的：

- ? `precision`。
- ? `recall`。
- ? `f1-score`。
- ? `support`。

用于更细致地查看正面、中性、负面分别表现如何。

`confusion_matrix.csv`

混淆矩阵数据。它记录模型把真实标签预测成各类标签的数量。

例如可以看出：

- ? 负面是否经常被预测成中性。
- ? 中性是否经常被预测成正面。
- ? 正面是否经常被预测成负面。

`confidence_summary.csv`

按分区和情感类别统计模型置信度。可以用来观察：

- ? 学习区正面弹幕平均置信度。
- ? 生活区负面弹幕平均置信度。
- ? 哪些类别模型比较不确定。

conflict_samples.csv

词典和模型意见冲突的样本。

例如：

- ? 词典偏正，但模型偏负。
- ? 词典偏负，但模型偏正。
- ? 模型判中性，但词典有明显情感词。

这个文件适合人工检查模型错误。

danmu_predicted.csv

最重要的预测结果文件。每一条弹幕都有一行，包含：

- ? 原始文本。
- ? 清洗后的文本。
- ? 分区。
- ? BV 号。
- ? 模型原始预测。
- ? 最终预测标签。
- ? 正面/中性/负面概率。
- ? 词典情感分数。
- ? 是否被人工标签覆盖。

如果你想逐条检查分类准不准，优先看这个文件。

experiment_summary.txt

本轮实验的整体摘要，记录：

- ? 输入视频。
- ? 原始弹幕路径。
- ? 采集总量。
- ? 学习区和生活区采集量。
- ? 训练数据路径。
- ? 最优模型。
- ? 输出目录。
- ? 图表目录。

它适合快速回顾某一轮实验做了什么。

`iteration_comparison.csv`

当前轮和上一轮实验结果的对比。可以看主动学习之后情感比例有没有变化。

不是第一轮时才会出现，所以数量可能比其他文件少。

`low_confidence_samples.csv`

模型低置信样本。也就是模型最不确定的弹幕。

这些样本适合人工标注，因为标它们通常能更有效提升下一轮模型效果。

`model_metrics.csv`

四个机器学习模型的对比结果。通常包含：

? 模型名称。

? accuracy。

? macro-F1。

程序会根据指标选择最优模型。

`positive_comments.csv`

最终判为正面的弹幕集合。适合人工抽查正面分类是否合理。

`negative_comments.csv`

最终判为负面的弹幕集合。适合人工抽查负面分类是否合理。

`neutral_comments.csv`

最终判为中性的弹幕集合。适合检查中性是否过多或过少。

`partition_sentiment_stats.csv`

学习区和生活区的情感占比统计。它是汇报里最重要的结果表之一。

通常用来回答：

? 学习区正面、负面、中性分别占多少。

? 生活区正面、负面、中性分别占多少。

? 两个分区的情绪分布有什么差异。

`review_samples.csv`

人工复核样本。前三轮会让你在终端对这里的样本填写标签。

标签规则：

? 1：正面。

? 0：中性。

? -1：负面。

程序下次运行会自动读取历史 `review_samples.csv`，把你标过的样本加入训练集。

`video_sentiment_stats.csv`

按视频统计情感比例。它比 `partition_sentiment_stats.csv` 更细，能看到每个 BV 号自己的情感分布。

6. `figures/` 图表目录

`figures/` 保存每次实验生成的图片。它和 `results/` 的实验结构对应。

目录结构示例：

```
figures/  
  experiment_20260528_145329/  
    round_1/  
    round_2/  
    round_3/  
    final_round_4/
```

每个轮次目录常见图片如下。

`partition_sentiment.png`

学习区和生活区情感占比图。用于展示两个分区正面、中性、负面的比例差异。

这是汇报中最常用的图。

`keywords_top15.png`

弹幕高频词 Top15 图。用于展示本次采集的弹幕中哪些词出现最多。

`model_metrics.png`

模型性能对比图。用于展示朴素贝叶斯、逻辑回归、SVM、随机森林的指标差异。

`confusion_matrix.png`

混淆矩阵图。用于观察模型最容易混淆哪些类别。

7. `annotated_code/` 注释阅读版目录

`annotated_code/` 是给人读代码用的，不参与正式运行。读完可以删除整个文件夹，不影响项目运行。

`annotated_code/README.md`

注释版代码目录说明，告诉你建议阅读顺序。

`annotated_code/README.pdf`

注释版目录说明的 PDF 版本。

`annotated_code/crawler_bilibili_annotated.py`

`src/crawler_bilibili.py` 的中文注释阅读版。用于理解爬虫怎么拿 BV、cid 和弹幕。

`annotated_code/crawler_bilibili_annotated.ipynb`

注释版爬虫代码的 Notebook 版本。

`annotated_code/make_sample_data_annotated.py`

`src/make_sample_data.py` 的中文注释阅读版。用于理解样例训练数据怎么生成。

`annotated_code/make_sample_data_annotated.ipynb`

注释版样例数据生成脚本的 Notebook 版本。

`annotated_code/run_experiment_annotated.py`

`src/run_experiment.py` 的中文注释阅读版。建议先看这个，因为它解释完整运行流程。

`annotated_code/run_experiment_annotated.ipynb`

注释版一键运行脚本的 Notebook 版本。

`annotated_code/train_analyze_annotated.py`

`src/train_analyze.py` 的中文注释阅读版。它解释清洗、特征、模型、预测、人工复核和输出结果。

`annotated_code/train_analyze_annotated.ipynb`

注释版核心分析脚本的 Notebook 版本。

`annotated_code/lexicon`说明.md

情感词典说明。它解释：

- ? `DEFAULT_POS_WORDS` 和 `DEFAULT_NEG_WORDS` 只是兜底小词表。
- ? 真正参与分析的是 `data/sentiment_lexicon/` 里的大词典。
- ? 程序会把默认词表和 HowNet/知网词典合并。

`annotated_code/lexicon`说明.pdf

词典说明的 PDF 版本。

`annotated_code/分类规则`说明.md

最终分类规则说明。它解释为什么要保留中性、哪些词直接判正面、哪些词直接判负面，以及哪些单字词容易误伤。

`annotated_code/分类规则`说明.pdf

分类规则说明的 PDF 版本。

8. `.ipynb` 文件说明

项目中所有 `.ipynb` 都是由 `.py` 转换而来，方便在 Jupyter Notebook 或 VS Code Notebook 中阅读。

注意：

- ? `.ipynb` 主要用于阅读和展示。
- ? 正式运行仍建议使用 `.py`。
- ? 尤其是 `run_experiment.py` 需要终端交互输入 BV 号，在 Notebook 里运行不一定更顺手。

9. `.pdf` 文件说明

项目中有多类 PDF：

- ? `README.pdf`：项目使用说明。
- ? `annotated_code/*.pdf`：注释版说明。
- ? `results/**/analysis_summary.pdf`：每轮实验摘要。
- ? `项目文件讲解.pdf`：当前这份项目文件说明。

PDF 主要用于提交、打印和阅读，不参与程序运行。

10. 哪些文件必须保留

如果只是要保证项目能正常运行，至少保留：

```
src/  
data/danmu_sample_5000.csv  
data/sentiment_lexicon/  
requirements.txt  
README.md
```

如果还要保留历史实验结果，则保留：

```
data/experiments/  
results/  
figures/
```

如果要交作业或答辩，则建议保留：

```
项目报告 docx  
展示 PPT  
README.md / README.pdf  
项目文件讲解.pdf  
results/最新实验/final_round_4/  
figures/最新实验/final_round_4/
```

11. 哪些文件可以删除

以下文件或目录不是程序运行必需：

- ? `annotated_code/`：只是阅读代码用。
- ? `*.ipynb`：Notebook 阅读版，正式运行不需要。
- ? `*.pdf`：说明文档或摘要 PDF，正式运行不需要。
- ? 旧的 `results/experiment_xxx/`：旧实验结果，不想保留可以删除。
- ? 旧的 `figures/experiment_xxx/`：旧实验图表，不想保留可以删除。

但如果要提交作业或展示成果，不建议随便删除报告、PPT、最终实验结果和最终图表。

12. 推荐查看顺序

如果你只是想运行项目：

1. 看 `README.md`。
2. 运行 `python src\run_experiment.py`。
3. 看 `results/实验名/final_round_4/analysis_summary.md`。

4. 看 `figures/实验名/final_round_4/partition_sentiment.png`。

如果你想理解代码：

1. 看 `annotated_code/run_experiment_annotated.py`。
2. 看 `annotated_code/crawler_bilibili_annotated.py`。
3. 看 `annotated_code/train_analyze_annotated.py`。
4. 看 `annotated_code/分类规则说明.md`。

如果你想检查分类结果：

1. 看 `results/实验名/final_round_4/danmu_predicted.csv`。
2. 看 `positive_comments.csv`、`negative_comments.csv`、`neutral_comments.csv`。
3. 看 `review_samples.csv`，继续人工标注不确定样本。

13. 最重要的最终输出

最终汇报时最关键的是：

```
results/最新实验/final_round_4/partition_sentiment_stats.csv
results/最新实验/final_round_4/danmu_predicted.csv
results/最新实验/final_round_4/analysis_summary.md
figures/最新实验/final_round_4/partition_sentiment.png
figures/最新实验/final_round_4/keywords_top15.png
figures/最新实验/final_round_4/model_metrics.png
figures/最新实验/final_round_4/confusion_matrix.png
```

其中 `partition_sentiment_stats.csv` 和 `partition_sentiment.png` 是讲“学习区和生活区情感差异”的核心依据。